

复现结果与其使用说明

本文件用于展示复现结果并进行简单的分析。

受 API 额度与时间成本限制，本文中作者源代码 API 改造版与 MASFactory 复现版的结果均来自一次完整运行，未进行多次重复实验。因此，本文不将小幅差异解释为统计显著优势，而主要将这些结果作为复现一致性与过程行为的证据。更具体地说，Acc、F1、病例级对照、分病种准确率和每轮准确率用于回答两个问题：其一，MASFactory 复现版是否在相同 API 模型设置下达到作者源代码 API 改造版的主要性能水平；其二，两版在多轮问诊过程中是否呈现相近的诊断变化趋势。

1 复现版与源代码的不同

MASFactory 的 Agent 逻辑会对大模型的输入输出进行 JSON 格式化处理，因此 MASFactory 复现版与作者源代码 API 改造版的提示词存在细微差别。该差别主要体现在 CoT 指令是否能够被模型稳定执行。

作者源代码中，“请你一步步思考”位于提示词结尾，LLM 较容易继续输出思考过程；而 MASFactory 复现版的 Inquiry Agent 提示词末尾主要强调结构化输出字段，具体形式如下：

REQUIRED OUTPUT FIELDS AND THEIR DESCRIPTIONS:

```
{
  "selection_output": "Inquiry Agent 的症状选择结果"
}
```

在该约束下，模型更倾向于只返回症状选择结果，CoT 内容不会稳定出现在输出中。实验中曾尝试增加 `output_reasoning` 字段，或将 `selection_output` 的描述扩展为“Inquiry Agent 的一步步思考过程和症状选择结果”，但准确率反而明显下降。因此，最终 MASFactory 复现版保留当前 JSON 输出约束，不额外启用 CoT 字段。该差异属于复现实现中的提示词格式差异，后续对比时需要作为潜在影响因素记录。

2 Acc结果对比分析

表 1: DDO 论文原文、作者源代码 API 改造版与 MASFactory 复现版的实验结果对比。API 结果为单次完整运行结果。

Method	LLM	DXY			GMD			CMD		
		Acc.init	Acc	Avg.n	Acc.init	Acc	Avg.n	Acc.init	Acc	Avg.n
论文原文	Qwen2.5-14B-Instruct	66.30	94.20	10.00	67.80	80.30	9.80	65.30	68.60	10.00
	Qwen2.5-7B-Instruct	66.30	87.50	9.90	69.50	79.50	9.60	60.60	63.60	10.00
	Qwen2.5-7B-Instruct <i>w/o adapter</i>	66.50	86.50	–	63.60	78.70	–	54.20	54.20	–
DDO源代码API版	gpt-4o-mini	65.00	93.20	10.00	62.80	79.10	9.80	62.90	61.10	10.00
DDO_MASFactory	gpt-4o-mini	64.10	98.10	10.00	63.60	78.70	9.80	62.90	63.00	10.00

Acc.init 与 Acc 均采用“并列第一算正确”的统计规则。

由表 1 可见，在相同的 gpt-4o-mini 设置下，MASFactory 复现版的初始诊断准确率与作者源代码 API 改造版基本接近。

经过多轮问诊后，在本次运行中，MASFactory 复现版在 DXY 和 CMD 上分别高出 4.90 和 1.90 个百分点，在 GMD 上低 0.40 个百分点。

整体来看，复现版基本保持了作者源代码 API 改造版的实验趋势；其中 DXY 和 GMD 在问诊后提升明显，CMD 的提升幅度相对有限。与论文原文结果相比，差异还受到底座模型、API 调用方式和提示词格式的共同影响。

3 F1 分数对比分析

表 2: 三个数据集上的 F1 分数对比。API 结果为单次完整运行结果。

Method	DXY		GMD		CMD	
	macro-F1	micro-F1	macro-F1	micro-F1	macro-F1	micro-F1
论文原文	93.60	93.30	81.60	80.30	65.80	67.40
DDO源代码API版	93.36	93.20	80.26	79.08	58.05	61.10
DDO_MASFactory	98.06	98.06	79.28	78.66	60.03	63.04

表 2 表明，在本次运行中，MASFactory 复现版在 DXY 上的 macro-F1 和 micro-F1 均达到 98.06，高于作者源代码 API 改造版；在 GMD 上略低于源代码 API 改造版；在 CMD 上则分别高出 1.98 和 1.94 个百分点。该结果说明，MASFactory 复现版没有出现明显的类别层面退化，但不同数据集上的类别分布、病例难度和模型输出随机性会放大两版实现之间的细微差异。

4 病例级对照结果

表 3: MASFactory 复现版与作者源代码 API 改造版的病例级对照结果。统计规则为：若真实标签位于最高置信度并列集合中，则该病例视为预测正确。

Dataset	Total	Both Correct	Both Wrong	MAS Correct / Source Wrong	MAS Wrong / Source Correct	Net Gain
DXY	103	95	1	6	1	+5
GMD	239	177	39	11	12	-1
CMD	1342	536	212	310	284	+26

由表 3 可见：

MASFactory 复现版在 DXY 上相对源代码 API 改造版净增加 5 个正确病例，在 CMD 上净增加 26 个正确病例，在 GMD 上净减少 1 个正确病例。GMD 的净差异很小，说明两版在该数据集上总体接近；

CMD 中“MAS Correct / Source Wrong”和“MAS Wrong / Source Correct”的病例数均较多，表明两版在大量具体病例上的判断并不完全一致，但 MASFactory 复现版最终仍取得正向净增益。

5 分病种诊断准确率分析

本节沿用原论文在 GMD 数据集上进行分病种诊断效果分析的思路，用于观察多轮问诊对不同疾病类别的影响。由于 API 结果仅进行单次运行，本节更关注趋势是否一致，而不将逐病种的小幅差异解释为稳定优势或劣势。




图 1: GMD 数据集上的分病种诊断准确率对比




图 2: 原论文中 GMD 数据集的分病种诊断准确率雷达图。

图 1(a)(b) 均表明，作者源代码 API 改造版大部分病种在问诊后取得提升。

图 1(b) 显示，MASFactory 复现版在 GMD 的多数病种上经过问诊后准确率有所提升，其中冠心病、甲状腺炎、结膜炎、食管炎和鼻炎的提升较明显。肺炎的准确率在问诊前后均保持较低水平，说明该类病例对当前复现流程仍较困难。

图 1(a) 与图 1(b) 对照可见，两版在冠心病、皮炎、食管炎和鼻炎等病种上的趋势较一致；差异主要出现在肺炎、肠炎、脑外伤、甲状腺炎和结膜炎等类别上。这说明总体指标接近并不代表逐病种表现完全一致。

图 1(a)(b) 与图 2 对照可见，三者的整体轮廓较为相像，均表现为问诊后的准确率曲线整体位于初

始诊断曲线外侧，说明多轮症状询问通常能够提升 GMD 数据集上的分病种诊断表现。具体来看，冠心病、食管炎、鼻炎等病种在三组结果中都具有较明显的问诊收益，而肺炎在三组结果中均处于相对较低水平，是较难通过当前问诊流程稳定提升的类别。不过，三者并非逐病种完全重合：作者源代码 API 改造版与 MASFactory 复现版在肺炎、肠炎、脑外伤、甲状腺炎和结膜炎等类别上存在局部差异；与论文原图相比，部分病种的初始准确率和问诊后提升幅度也有所变化。这说明 MASFactory 复现版在总体趋势上复现了 DDO 的主要行为，但逐病种表现仍会受到底座模型、API 调用方式、提示词格式以及模型输出随机性的影响。

6 每轮诊断准确率分析

本节为额外过程分析，不对应原论文 Figure 3。原论文 Figure 3 比较的是不同最大问诊轮数设置下的结果；本文统计的是同一次 `max_turn=10` 运行中 Turn=0 到 Turn=10 的逐轮诊断准确率，用于观察问诊过程中信息是否有效累积。




图 3: 三个数据集上每轮诊断准确率变化。Turn=0 表示未进行症状询问时的初始诊断结果，Turn=1–10 表示每轮问诊后的诊断结果。图中标注为对应轮次的正确病例数/测试集总病例数。

由图 3 可见：

DXY 上 MASFactory 复现版前期提升速度略慢，但第 8 轮后继续上升，并在第 10 轮达到 101/103，高于源代码 API 改造版的 96/103。

GMD 上两条曲线整体接近，最终仅相差 1 个病例。

CMD 上两版曲线波动更明显，MASFactory 复现版在前几轮出现下降，随后逐步回升，最终达到 846/1342，比源代码 API 改造版多 26 个正确病例。整体来看，复现版保留了 DDO 随问诊逐步修正诊断预测的主要趋势。